Modularity i jego modyfikacje w rodzinach grafów gęstych

Zofia Kuriata

Politechnika Wrocławska

28 stycznia 2026

Modularity

Modularity

Miara jakości podziału grafu na społeczności.

Definicja

G graf z co najmniej jedną krawędzią, $\mathcal{A}$ partycja zbioru wierzchołków G.

Modularity score $\mathcal{A}$ wynosi $mod_{\mathcal{A}}(G) = \sum_{A \in \mathcal{A}} \left(\frac{e(A)}{e(G)} - \left(\frac{vol(A)}{vol(G)} \right)^2 \right)$.

Modularity grafu G wynosi $mod(G) = \max_{\mathcal{A} \in \mathcal{P}(V)} mod_{\mathcal{A}}(G)$.

Modularity

Zastosowanie

- Analiza sieci społecznych, biologicznych, informatycznych.
- Algorytmy klasteryzacji Louvain, Leiden.

Wady

- *Resolution limit* - pomijanie małych społeczności w dużych grafach.
- Ignorowanie wewnętrznej struktury społeczności.
- Nienaturalnie duże wartości.

Modularity star

Modularity star

Zmodyfikowana wersja modularity eliminująca niektóre wady klasycznej wersji.

Definicja

G graf z co najmniej jedną krawędzią, $\mathcal{A}$ partycja zbioru wierzchołków G.

Modularity star score $\mathcal{A}$ wynosi
$mod^*_{\mathcal{A}}(G) = \sum_{A \in \mathcal{A}} \left(\frac{e(A)}{e(G)} - \left(\frac{vol(A)}{vol(G)} \right)^2 \right) \cdot \left(\frac{\Delta(A)+1}{|A|} \right)$, gdzie $\Delta(A)$ to maksymalny wewnętrzny stopień wierzchołka w społeczności A.

Modularity star grafu G wynosi $mod^*(G) = \max_{\mathcal{A} \in \mathcal{P}(V)} mod^*_{\mathcal{A}}(G)$.

Cel

W literaturze większość badań dotyczy grafów rzadkich, ja natomiast skupiłam się na **grafach gęstych**.

Cele pracy

- Własności: modularity $\rightarrow$ na modularity star.
- Ograniczenie górne na modularity star.
- Liczba krawędzi do usunięcia z K_n, aby $mod^* > 0$.
- Hipotetyczna odpowiedź na pytanie czy istnieje G, dla którego $mod^*(G) > mod(G)$.

Zachowane własności

G graf z co najmniej jedną krawędzią, $\mathcal{A}$ partycja zbioru wierzchołków G.

W pracy wykazałam, że następujące własności modularity przenoszą się na modularity star.

- $-\frac{1}{2} \leq mod^*_{\mathcal{A}}(G) < 1$.
- Jeśli $|\mathcal{A}| \leq 2$ oraz $\max_{\mathcal{B}:|\mathcal{B}|\leq 2}(mod^*_{\mathcal{B}}(G)) = mod^*_{\mathcal{A}}(G)$, to

$$\forall_{A\in\mathcal{A}}\ mod^*_A(G) \geq 0.$$

- Jeśli $mod^*_{\mathcal{A}}(G) = mod^*(G)$, to $\mathcal{A}$ nie zawiera społeczności składającej się z pojedynczego wierzchołka stopnia 1.
- $(mod(G) = 0) \Leftrightarrow (mod^*(G) = 0)$.

Górne ograniczenie na modularity star

W pracy zaproponowałam następujące ograniczenie górne na modularity star

Twierdzenie

Dla grafu $G = (V, E)$, gdzie $|V| = n$:

$$mod^*(G) \leq \frac{n^2}{2} \cdot \max_{\mathcal{B}:|\mathcal{B}|\leq 2} mod^*_{\mathcal{B}}(G)$$

Wniosek

Pozwala ono na ograniczenie wartości modularity star grafu poprzez przejrzenie jedynie partycji co najwyżej dwuelementowych. Jest szczególnie użyteczne w celu sprawdzenia czy modularity star danego grafu jest dodatnie.

Grafy prawie pełne

Graf pełny K_n

- dla $n \geq 1$ mamy $mod(K_n) = 0$ oraz $mod^*(K_n) = 0$,
- dla $n \geq 4$ istnieje graf G o n wierzchołkach, dla którego $mod(G) > 0$ oraz $mod^*(G) > 0$.

Funkcja $f^*(n)$**:** Minimalna liczba krawędzi do usunięcia z K_n, aby uzyskać $mod^*(G) > 0$.

Wynik

Dla każdej liczby naturalnej $n \geq 4$:

$$f^*(n) = \left\lfloor \frac{n}{2} \right\rfloor + 1.$$

Grafy prawie pełne dwudzielne

Graf pełny dwudzielny $K_{s,t}$

Dla $s, t \geq 1$:

$$mod(K_{s,t}) = 0 \quad \text{oraz} \quad mod^*(K_{s,t}) = 0$$

Oznaczenie $\delta_*^-(G)$: Minimalna liczba krawędzi do usunięcia z G, aby $mod^*(G') > 0$.

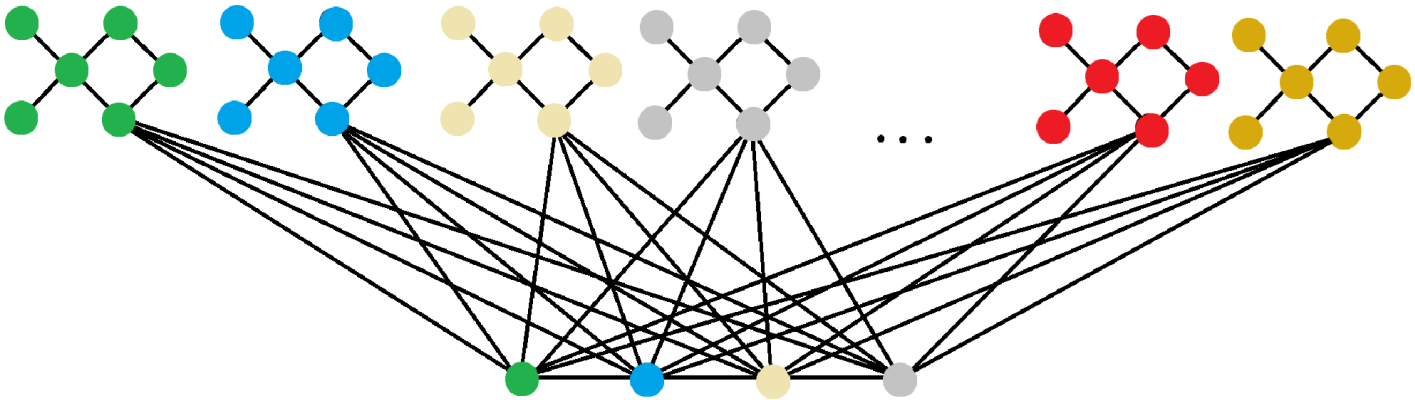
Wynik

Dla $s, t \geq 1$:

$$\delta_*^-(K_{s,t}) = 1$$

Hipoteza 1: Ujemna kontrybucja

Jeśli $mod^*_{\mathcal{A}}(G) = mod^*(G)$, to możliwe jest istnienie społeczności w $\mathcal{A}$, która **kontrybuuje ujemnie** do mod star.



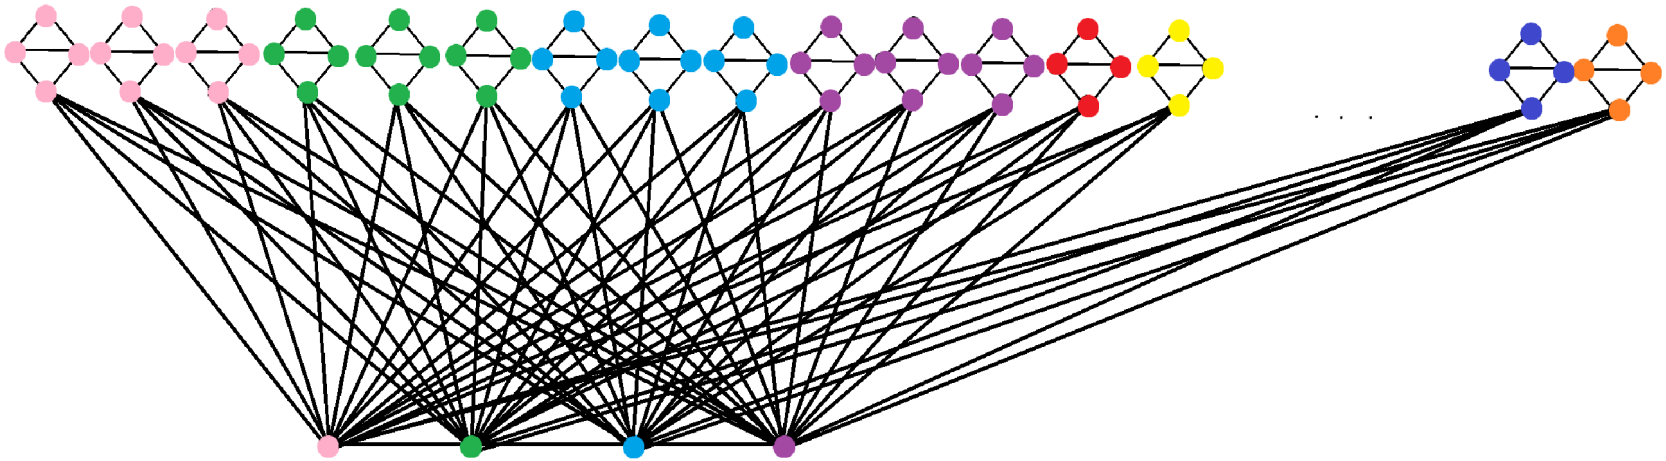
Rysunek: Ilustracja hipotezy.

Wnioski:

- Dodawanie izolowanych wierzchołków wpływa na mod^*.
- Społeczności w optymalnej partycji nie muszą indukować spójnych podgrafów.

Hipoteza 2: $mod^* > mod$

Istnieje graf G, dla którego $mod^*(G) > mod(G)$.



Rysunek: Graf G, dla którego hipotetycznie $mod^*(G) > mod(G)$.

Największa znaleziona wartość $mod^*_{\mathcal{A}}(G) \approx 0.5511554446$.

Największa znaleziona wartość $mod_{\mathcal{A}}(G) \approx 0.54413127767$.

Poszukiwania

Proces, który doprowadził do znalezienia G:

1. Wyznaczenie warunków koniecznych, aby możliwe było spełnienie nierówności.
2. Stworzenie modelu garfu spełniającego te warunki.
3. Eksperymentalne dobranie parametrów.
4. Testowanie sensownych partycji zbioru jego wierzchołków.

Warunki konieczne

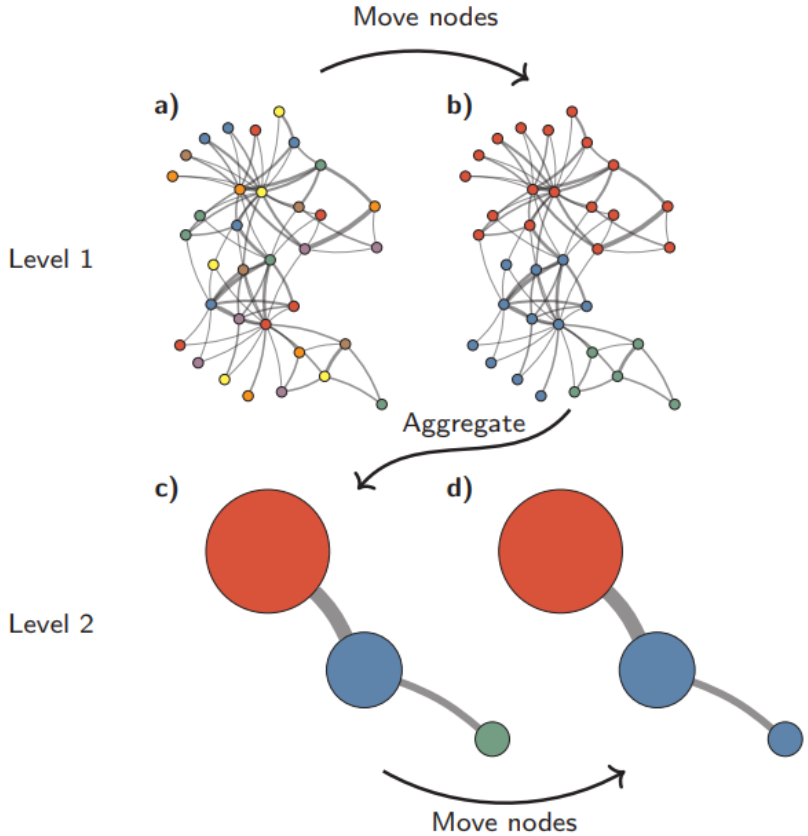
- Najlepsze partycjonowanie dla mod i mod star muszą być różne.
- W optymalnym partycjonowaniu dla mod star musi istnieć ≥ 1 społeczność kontrybuująca ujemnie.
- Graf musi zawierać "rzadką" strukturę oraz pewną liczbę odpowiednio "gęstych" struktur.

Algorytm Louvain

Algorytm Louvain służy do wykrywania społeczności w dużych grafach poprzez maksymalizację modularity score.

1. **Lokalna optymalizacja mod score**
   - Każdy węzeł to osobna społeczność.
   - Przenosimy węzeł do sąsiada tylko, jeśli **zwiększa to mod score**.
   - Powtarzamy do osiągnięcia lokalnego maksimum.
2. **Budowa meta-grafu**
   - Społeczności stają się nowymi węzłami.
   - Krawędzie są sumowane.

Proces iteruje, dopóki mod score może rosnąć.

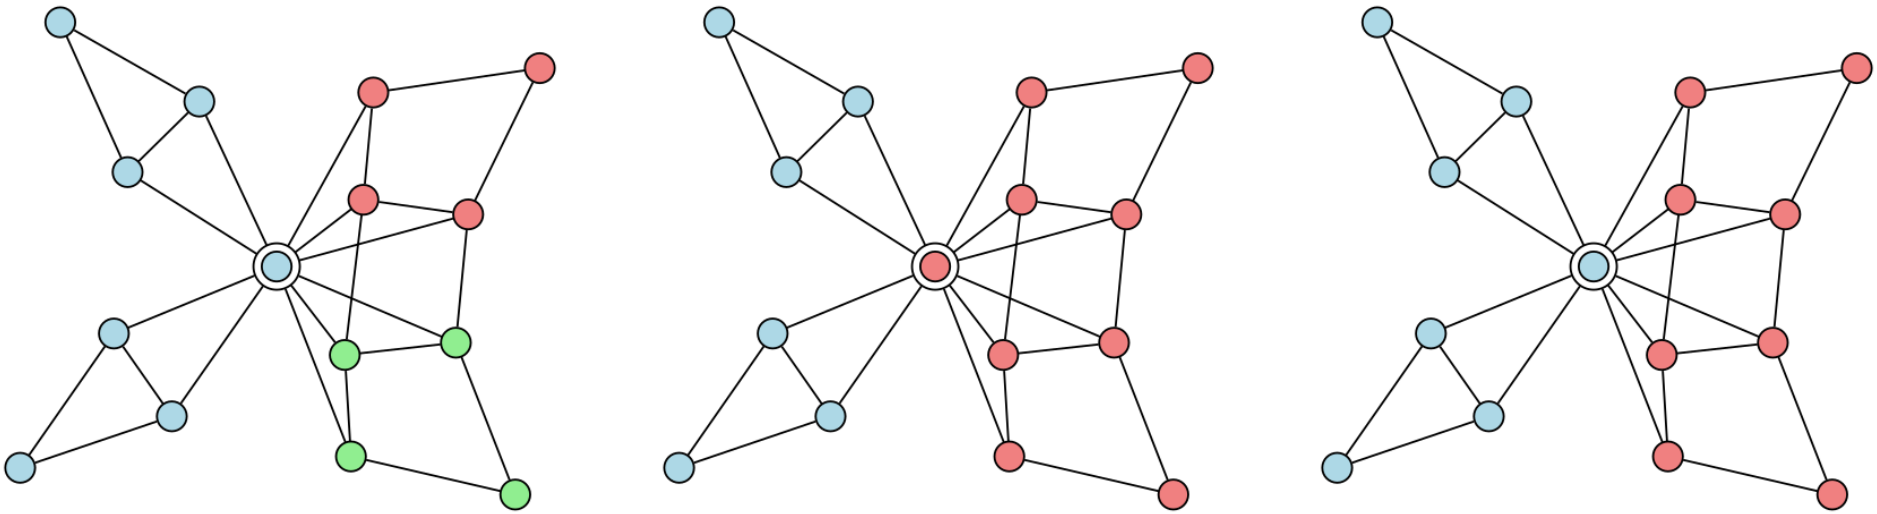


Rysunek: Algorytm Louvain [9].

Algorytm Leiden

Ulepszona wersja alogrytmu Louvain. Rozwiązuje problem **niespójnych społeczności** oraz **resolution limit**. Wprowadza 3. fazę mającą na celu korektę nowopowstałego podziału na społeczności w fazie 1.

1. **Lokalna optymalizacja**.
2. **Refinement**.
3. **Agregacja**.



https://en.wikipedia.org/wiki/Leiden_algorithm

Złożoność obliczeniowa

Problem decyzyjny wyznaczenia modularity jest **NP-zupełny**.

Przynależność do klasy NP

Dla danej partycji $\mathcal{A}$ i progu k, warunek $mod_{\mathcal{A}}(G) \geq k$ weryfikujemy w czasie wielomianowym.

NP-trudność

Istnieje redukcja z silnie NP-zupełnego problemu **3-partition** do problemu modularity [6].

Redukcja

Dla instancji 3-partition $A = \{a_1, \ldots, a_{3k}\}$ budujemy graf $G(A)$ oraz wyznaczamy próg $K(A)$.

Struktura grafu:

- k klik o rozmiarze $a = \sum_{i=1}^{3k} a_i$.
- Dla każdego a_i wierzchołek dodatkowy v_i.
- v_i połączony z a_i wierzchołkami **każdej** kliki.

Stopnie wierzchołków:

- Węzeł kliki: a.
- Węzeł v_i: $k \cdot a_i$.
- Suma stopni: $2m = k \cdot a^2 + k \cdot a$.

W optymalnej partycji $\mathcal{A}$ każda społeczność składa się z dokładnie 1 kliki i pewnej liczby dodatkowych wierzchołków v_i.

Redukcja

Mamy

- $mod_{\mathcal{A}}(G(A)) = EC_{\mathcal{A}} - DT_{\mathcal{A}}$,
- $EC_{\mathcal{A}}(G(A)) = \frac{m-(k-1)a}{m} = 1 - \frac{2k-2}{k(a+1)}$,
- $DT_{\mathcal{A}}(G(A)) = \frac{1}{k^2a^2(a+1)^2} \cdot \sum_{A \in \mathcal{A}} vol(A)^2$.

Maksymalizacja modularity score

$DT_{\mathcal{A}}(G(A))$ osiąga minimum równe $\frac{k(a^2+a)^2}{k^2a^2(a+1)^2}$, gdy sumy stopni dodatkowych wierzchołków w każdej z k społeczności są równe i wynoszą $k \cdot \frac{1}{k} \cdot a = a$. Odpowiada to idealnemu podziałowi zbioru A na podzbiory o sumie $b = \frac{1}{k} \cdot a$.

Wyznaczenie progu

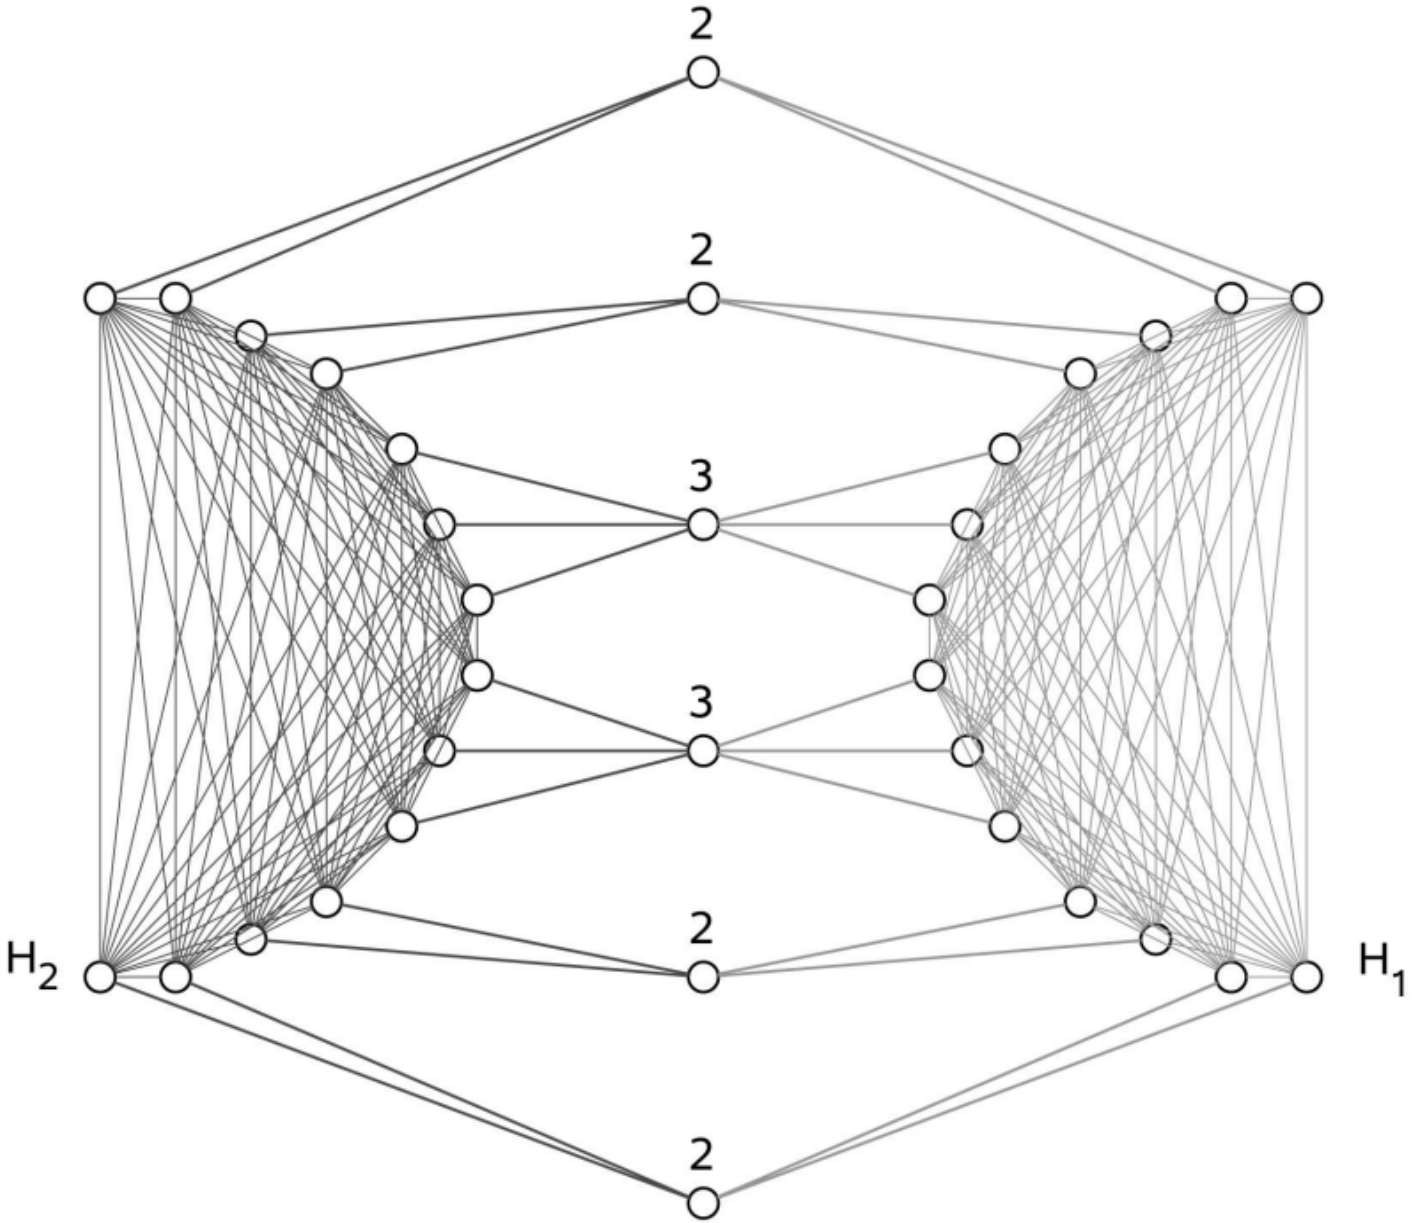
$$K(A) = 1 - \frac{2k-2}{k(a+1)} - \frac{ka^2(a+1)^2}{k^2a^2(a+1)^2} = \frac{(k-1)(a-1)}{k(a+1)}$$

Poprawność redukcji

Istnienie 3-partycji dla zbioru A

$$\Longleftrightarrow$$

$$mod(G(A)) \geq \frac{(k-1)(a-1)}{k(a+1)}$$



[6]

Liczby Bella

Definicja: B_n to liczba wszystkich możliwych partycji zbioru n-elementowego.

$$B_n = \sum_{k=0}^{n} \left\{ {n \atop k} \right\}$$

Rekurencja:

$$B_{n+1} = \sum_{k=0}^{n} \binom{n}{k} B_k.$$

Tempo wzrostu: $a^n < B_n < n!$.

1

1 2

2 3 5

5 7 10 15

15 20 27 37 52

Liniowe równanie diofantyczne: $at - bs = 1$

Zakładamy, że NWD$(t, s) = 1$.

- **Rozwiązanie szczególne:** Wyznaczamy (a, b) za pomocą Rozszerzonego Algorytmu Euklidesa tak, aby $at - bs = 1$.
- **Rozwiązanie ogólne:** Wszystkie pary (a', b') spełniające równanie dane są wzorami:

$$\begin{cases} a' = a + s \cdot k \\ b' = b + t \cdot k \end{cases} \quad \text{dla } k \in \mathbb{Z}.$$

$$a't - b's = (a + s \cdot k)t - (b + t \cdot k)s = at - bs + skt - tks = 1$$

Rozszerzony Algorytm Euklidesa

Cel algorytmu

Wyznaczenie współczynników całkowitych a i b takich, że:

$$at + bs = \text{NWD}(t, s)$$

Procedura krok po kroku:

1. **Algorytm Euklidesa:** Wykonujemy dzielenia z resztą, aż otrzymamy resztę 0.
2. **Wyznaczenie reszt:** Zapisujemy każde z powyższych równań w postaci: $\textit{reszta} = \textit{dzielna} - \textit{iloraz} \cdot \textit{dzielnik}$.
3. **Podstawianie wsteczne:** Zaczynamy od równania z ostatnią niezerową resztą (NWD) i sukcesywnie podstawiamy poprzednie reszty, aż uzyskamy kombinację liczb t i s.

Przykład

Przykład: $120a - 23b = 1$

- $120 = 5 \cdot 23 + 5 \implies 5 = 120 - 5 \cdot 23$
- $23 = 4 \cdot 5 + 3 \implies 3 = 23 - 4 \cdot 5$
- $5 = 1 \cdot 3 + 2 \implies 2 = 5 - 1 \cdot 3$
- $3 = 1 \cdot 2 + 1 \implies 1 = 3 - 1 \cdot 2$

Wstecz:

$1 = 3 - 1 \cdot (5 - 3) = 2 \cdot 3 - 5 = 2 \cdot (23 - 4 \cdot 5) - 5 = 2 \cdot 23 - 9 \cdot 5 =$
$2 \cdot 23 - 9 \cdot (120 - 5 \cdot 23) = -9 \cdot 23 + 47 \cdot 23$

Zatem $a = -9, b = -47$. Mamy $a' = -9 + 23 = 14$ oraz
$b' = -47 + 120 = 73$


Colin McDiarmid, Fiona Skerman.
Modularity of nearly complete graphs and bipartite graphs.
arXiv preprint arXiv:2311.06875, 2023.


Thang N. Dinh, My T. Thai.
Finding Community Structure with Performance Guarantees in Scale-Free Networks.
W: *2011 IEEE Third International Conference on Privacy, Security, Risk and Trust and 2011 IEEE Third International Conference on Social Computing*, s. 888–891. IEEE, 2011.


Thang N. Dinh, Ying Xuan, My T. Thai.
Towards Social-aware Routing in Dynamic Communication Networks.
W: *Proceedings of the 34th IEEE Conference on Local Computer Networks (LCN)*, s. 202–205. IEEE, 2009.


Michał Lasoń, Małgorzata Sulkowska.
Modularity of minor-free graphs.
Journal of Graph Theory, 102(4):728–736, 2023.


Colin McDiarmid, Fiona Skerman.

Modularity of regular and treelike graphs.
Journal of Complex Networks, 6(4):596–619, 2018.


Ulrik Brandes, Daniel Delling, Marco Gaertler, Robert Görke, Martin Hoefer, Zoran Nikoloski, Dorothea Wagner.
On Modularity Clustering.
IEEE Transactions on Knowledge and Data Engineering, 20(2):172–188, 2008.


Mark E.J. Newman, Michelle Girvan.
Finding and evaluating community structure in networks.
Physical Review E, 69(2):026113, 2004.


Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte, Etienne Lefebvre.
Fast unfolding of communities in large networks.
Journal of Statistical Mechanics: Theory and Experiment, 2008(10):P10008, 2008.


Vincent Traag, Ludo Waltman, Nees Jan van Eck.
From Louvain to Leiden: guaranteeing well-connected communities.

Scientific Reports, 9:5233, 2019.


Santo Fortunato, Marc Barthélemy.
Resolution limit in community detection.
Proceedings of the National Academy of Sciences (PNAS), 104(1):36–41, 2007.


Mikołaj Krupiński.
Algorytmy wykrywania społeczności w sieciach oparte na różnych wersjach definicji modularity.
Praca dyplomowa, Politechnika Wrocławska, 2024.